

RESUMÉ DES COURS

→ statistiques descriptives:

- moyenne : $\frac{1}{n} \sum_{i=1}^n x_i$ est sensible aux valeurs extrêmes ou aberrantes
mais offre des propriétés algébriques intéressantes : connaît les moyennes de 2 sous-populations permet de calculer la moyenne à l'intérieur de la population totale.

médiane: c'est la valeur seuil telle que, si on divise la population selon 1 critère donné, elle la sépare en 2 sous-populations de taille égale.

elle n'est pas sensible aux variations critiques ou alternantes.

- tableau crée :

On étudie les liens de X et Y ainsi que la relation entre les variables

On suppose que X ne possède que 2 modalités : 1 et 0.

et qu'Y

= beta l

x	y	k	l	
i	nik	n;l	n;	
j	njk	njl	nj	
	n;k	n;l	n	

$$\begin{aligned} \text{les fréquences peuvent être interprétées comme des probabilités} \\ F_{i,k} = \frac{n_{i,k}}{n} = P(X=i, Y=k) \quad F_{j,k} = \frac{n_{j,k}}{n} = P(X=j, Y=k) \\ F_{i,l} = \frac{n_{i,l}}{n} = P(X=i, Y=l) \quad F_{j,l} = \frac{n_{j,l}}{n} = P(X=j, Y=l) \end{aligned}$$

$$\text{avec : } F_{0,k} = \frac{n \cdot k}{n} = \mathbb{P}(Y=k)$$

$$F.l = \frac{n.l}{n} = P(Y=l)$$

$$F_{i.} = \frac{n_i}{n} = P(X=i)$$

$$F_{j-} = \frac{n_j}{n} = P(X=j)$$

$$\text{et: } F_{i|R} = \frac{n_{ik}}{n_R} = P(X=i | Y=R)$$

$$F_{i|l} = \frac{n_{il}}{n_l} = P(X=i | Y=l)$$

$$F_{j|k} = \frac{n_j k}{n_k} = P(X=j | Y=k)$$

$$F_j | \ell = \frac{n_{j\ell}}{n_\ell} = P(X=j | Y=\ell)$$

Variance: $\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$ est l'indicateur de dispersion.

Plus elle est élevée et plus les valeurs sont dispersées (mais elles sont homogènes)

- écart-type = racine carrée de la variance

- covariance entre X et Y :

$$\text{cov}(X, Y) = \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})$$

∇ X et Y sont indépendants alors: $\text{cov}(X, Y) = 0$

$\nabla \text{cov}(X, Y) \neq 0$ alors X et Y ne sont pas indépendantes

$\nabla \text{cov}(X, Y) = 0$ alors m ne peut pas coïncider.

- coefficient de corrélation linéaire:

$$\text{cor}(X, Y) = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y} \in [-1, 1]$$

on cherche 1 relation de type $Y = aX + b$

I) si $|\text{cor}(X, Y)| \geq 1$ alors la corrélation linéaire entre les 2 variables est forte

I-1) si $\text{cor}(X, Y) \geq 1$ alors Y est 1 fonction affine croissante de X ($a > 0$)

I-2) si $\text{cor}(X, Y) \leq -1$ alors Y est 1 fonction affine décroissante de X ($a < 0$)

II) si $\text{cor}(X, Y) = 0$ alors X et Y ne sont pas corrélées linéairement

mais on peut avoir 1 autre type de liaison ($Y = X^2$, par exemple)

$$* a = \frac{\text{cov}(X, Y)}{\text{V}[X]}$$

$$b = \bar{Y} - a\bar{X}$$

* La droite $Y = aX + b$ est appelée droite de régression linéaire

→ les espaces probabilisés: $(\Omega, \mathcal{A}, \mathbb{P})$

* \mathcal{A} est 1 tribu: $\mathcal{A} \subset \mathcal{P}(\Omega)$

$$\Omega \in \mathcal{A}$$

$$\forall A \in \mathcal{A}, A^c \in \mathcal{A}$$

$$\forall (A_i)_{i=1, \dots, n} \in \mathcal{A}, \bigcup_{i=1}^n A_i \in \mathcal{A}$$

* \mathbb{P} est 1 mesure de probabilité sur \mathcal{A} :

$$\mathbb{P}: \mathcal{A} \rightarrow [0, 1]$$

$$A \mapsto \mathbb{P}(A) = \mathbb{P}(\{w \in \Omega \mid w \in A\})$$

prop: $\mathbb{P}(\emptyset) = 0$

$$\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$$

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$$

si $A \subset B$ alors: $\mathbb{P}(A) \leq \mathbb{P}(B)$

[remarque: Soient $(A_n)_{n \geq 1}$ 1 suite d'événements: $\mathbb{P}\left(\bigcup_{i=1}^n A_i\right)$ est 1 suite croissante et majorée par 1 donc elle converge

$\mathbb{P}\left(\bigcap_{i=1}^n A_i\right)$ est 1 suite décroissante et minorée par 0 donc elle converge]

- probabilité conditionnelle:

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} \text{ avec } \mathbb{P}(B) \neq 0$$

- formule des probabilités totales:

$$\mathbb{P}_{\text{tot}}(B_i)_{i=1,\dots,n} \text{ 1 partition de } \Omega : \begin{cases} \bigcup_{i=1}^n B_i = \Omega \\ B_i \cap B_j = \emptyset \text{ si } i \neq j \end{cases}$$

$$\text{alors: } \forall A \in \mathcal{F}, \mathbb{P}(A) = \mathbb{P}(A \cap \Omega) = \mathbb{P}\left(A \cap \left(\bigcup_{i=1}^n B_i\right)\right) = \sum_{i=1}^n \mathbb{P}(A \cap B_i) = \sum_{i=1}^n \mathbb{P}(A|B_i) \mathbb{P}(B_i)$$

[1 exemple: $\forall n \in \mathbb{N}, A_n : \Omega \rightarrow \{a, b, c\}$

$$\text{on a: } \mathbb{P}(A_n = a) = \mathbb{P}(A_n = a | A_{n-1} = a) \mathbb{P}(A_{n-1} = a) + \mathbb{P}(A_n = a | A_{n-1} = b) \mathbb{P}(A_{n-1} = b) + \mathbb{P}(A_n = a | A_{n-1} = c) \mathbb{P}(A_{n-1} = c)$$

$$\mathbb{P}(A_n = b) = \mathbb{P}(A_n = b | A_{n-1} = a) \mathbb{P}(A_{n-1} = a) + \mathbb{P}(A_n = b | A_{n-1} = b) \mathbb{P}(A_{n-1} = b) + \mathbb{P}(A_n = b | A_{n-1} = c) \mathbb{P}(A_{n-1} = c)$$

$$\mathbb{P}(A_n = c) = \mathbb{P}(A_n = c | A_{n-1} = a) \mathbb{P}(A_{n-1} = a) + \mathbb{P}(A_n = c | A_{n-1} = b) \mathbb{P}(A_{n-1} = b) + \mathbb{P}(A_n = c | A_{n-1} = c) \mathbb{P}(A_{n-1} = c)$$

et donc les probabilités de A_n en fonction des A_{n-1}

- formule de Bayes:

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(B|A) \mathbb{P}(A)}{\mathbb{P}(B)}$$

- A et B sont 2 événements indépendants $\Leftrightarrow \mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$

\rightarrow les variables aléatoires discrètes:

X: $\Omega \rightarrow X(\Omega)$ qui prend 1 nb finie infini de valeurs.

- loi de X:

$$\forall x \in X(\Omega), \mathbb{P}(X=x)$$

- fonction de répartition de X:

$$F: \mathbb{R} \rightarrow [0; 1]$$

$$x \mapsto \mathbb{P}(X \leq x)$$

- espérance de X: $\mathbb{E}[X] = \sum_{x \in X(\Omega)} x \mathbb{P}(X=x)$

- Si $Y = g(X)$: $Y: \Omega \rightarrow g(X(\Omega))$

$$\mathbb{P}(Y=y) = \mathbb{P}(g(X)=y) = \mathbb{P}(X \in g^{-1}(y))$$

- variance de X: $\mathbb{V}[X] = \mathbb{E}[X^2] - \mathbb{E}[X]^2$ formule de Huyghens-König

$$\text{avec: } \mathbb{E}[X^2] = \sum_{x \in X(\Omega)} x^2 \mathbb{P}(X=x)$$

- covariance de X et Y: $\text{cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$

$$\mathbb{V}[X+Y] = \mathbb{V}[X] + \mathbb{V}[Y] + 2\text{cov}(X, Y)$$

- vecteur aléatoire discret:

$$X: \mathbb{N} \rightarrow X_1(\mathbb{N}) \times X_2(\mathbb{N}) \times X_3(\mathbb{N})$$

$$w \mapsto \begin{pmatrix} X_1(w) \\ X_2(w) \\ X_3(w) \end{pmatrix} \quad \text{avec } (X_i)_{i=1,2,3} \text{ variables aléatoires discrètes}$$

- loi de X :

$$\forall (x_1 \in X_1(\mathbb{N}), x_2 \in X_2(\mathbb{N}), x_3 \in X_3(\mathbb{N}), P(X_1=x_1, X_2=x_2, X_3=x_3))$$

- loi marginale de X_1 :

$$\forall x_1 \in X_1(\mathbb{N}), P(X_1=x_1) = \sum_{\substack{x_2 \in X_2(\mathbb{N}) \\ x_3 \in X_3(\mathbb{N})}} P(X_1=x_1, X_2=x_2, X_3=x_3)$$

- loi conditionnelle de X sachant que $Y=y$:

$$\forall x \in X(\mathbb{N}), P(X=x | Y=y) = \frac{P(X=x, Y=y)}{P(Y=y)}$$

- indépendance de 2 v.a.d.:

$$\forall x \in X(\mathbb{N}), \forall y \in Y(\mathbb{N}), P(X=x, Y=y) = P(X=x) \cdot P(Y=y)$$

- indépendance de n v.a.d.:

$$\forall x_1 \in X_1(\mathbb{N}), \dots, x_n \in X_n(\mathbb{N}), P(X_1=x_1, \dots, X_n=x_n) = \prod_{i=1}^n P(X_i=x_i)$$

- si X et Y sont ind. alors: $E[XY] = E[X] \cdot E[Y]$

$$\text{cov}(X, Y) = 0$$

→ lois discrètes usuelles:

- loi de Bernoulli de paramètre p : $X: \mathbb{N} \rightarrow \{0, 1\}$

$$P(X=1) = p$$

- loi binomiale de paramètres n et p :

Q'est le nombre de succès obtenus si on répète indépendamment n épreuves de Bernoulli

$$X: \mathbb{N} \rightarrow [\![0; n]\!]$$

$$P(X=k) = C_n^k p^k (1-p)^{n-k} = \frac{n!}{k!(n-k)!} p^k (1-p)^{n-k}, \forall k \in [\![0; n]\!]$$

[exercice: notez: $X = \sum_{i=1}^n X_i$ avec X_i qui ont la loi de Bernoulli de paramètre p]

- loi géométrique de paramètre $p \in]0; 1[$

On considère l'expérience qui a la probabilité p de réussir, c'est le nombre de tentatives nécessaires pour obtenir 1 succès.

$$X: \mathbb{N} \rightarrow [\![0; +\infty]\!]$$

$$\forall n \geq 1, P(X=n) = (1-p)^{n-1} p$$

- loi de Poisson de paramètre $\lambda > 0$: $X: \mathbb{N} \rightarrow \mathbb{N}$

$$\forall k \in \mathbb{N}, P(X=k) = e^{-\lambda} \frac{\lambda^k}{k!}$$

→ variables aléatoires à densité:

- f est 1 densité si:

$$\textcircled{1} f: \mathbb{R} \rightarrow \mathbb{R}^+$$

$\textcircled{2}$ f est continue sur \mathbb{R} ou f est 1 nhl fini de pts

$$\textcircled{3} \int_{-\infty}^{+\infty} f(t) dt = 1$$

- $\forall (a; b) \in \mathbb{R}^2, \quad P(X \in [a; b]) = \int_a^b f(t) dt$

- fonction de répartition: $F_X: \mathbb{R} \rightarrow [0; 1]$

$$x \mapsto P(X \leq x) = \int_{-\infty}^x f(t) dt$$

- propriété: $F'_X(x) = f_X(x)$

$$- \mathbb{E}[X] = \int_{-\infty}^{+\infty} t f(t) dt$$

$$- V[X] = \mathbb{E}[X^2] - \mathbb{E}[X]^2$$

$$\text{avec: } \mathbb{E}[X^2] = \int_{-\infty}^{+\infty} t^2 f(t) dt$$

- densités usuelles:

- loi uniforme: $f(x) = \frac{1}{b-a} \mathbb{I}_{[a;b]}(x)$

- loi exponentielle de paramètre λ : $f(t) = \lambda e^{-\lambda t} \mathbb{I}_{[0; +\infty)}(t)$

- loi normale de paramètres μ et σ^2 : $f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$

- lois de $aX+b, X^2, e^X$?

$$* Y = X^2$$

fonction de répartition de Y ?

$$\text{soit } y \in \mathbb{R}^+, \quad P(Y \leq y) = P(X^2 \leq y) = P(-\sqrt{y} \leq X \leq \sqrt{y}) = F_X(\sqrt{y}) - F_X(-\sqrt{y})$$

[Dans ce cas, toujours poser pour la fonction de répartition]

- loi de X^2 à k degrés de liberté:

$$X \sim \chi^2(k) \Leftrightarrow X = \sum_{i=1}^k X_i^2 \text{ avec } X_i \sim N(0; 1) \text{ et } (X_i)_{i=1, \dots, k} \text{ mutuellement indépendantes}$$

$$- \mathbb{E}[X] = \sum_{i=1}^k \mathbb{E}[X_i^2] = k \mathbb{E}[X_1^2] \text{ car les } (X_i) \text{ sont de même loi}$$

$$= k [\mathbb{E}[X_1^2] - \mathbb{E}[X_1]^2] = k V[X_1] = k$$

$$- V[X] = 2k$$

dém: $V\left[\sum_{i=1}^k X_i^2\right] = \sum_{i=1}^k V[X_i^2]$ car les (X_i) ; sont mutuellement indépendantes
 $= k V[X_1^2]$ car les (X_i) ; ont la même loi
 $= k [\mathbb{E}[X_1^4] - \mathbb{E}[X_1]^2]$
 $= k [\mathbb{E}[X_1^4] - V[X_1]] = k [\mathbb{E}[X_1^4] - 1]$

il reste à montrer que: $\mathbb{E}[X_1^4] = 3$?

$$\mathbb{E}[X_1^4] = \int_{-\infty}^{+\infty} x^4 \frac{e^{-\frac{x^2}{2}}}{\sqrt{2\pi}} dx = \int_{-\infty}^{+\infty} x^3 \cdot x \frac{e^{-\frac{x^2}{2}}}{\sqrt{2\pi}} dx$$

On intégrera par parties en partant:

$$u' = x e^{\frac{-x^2}{2}} / \sqrt{2\pi} \Rightarrow u = -\frac{e^{\frac{-x^2}{2}}}{\sqrt{2\pi}}$$

$$v = x^3 \Rightarrow v' = 3x^2$$

$$\mathbb{E}[X_1^4] = \left[-x^3 \frac{e^{\frac{-x^2}{2}}}{\sqrt{2\pi}} \right]_{-\infty}^{+\infty} + 3 \int_{-\infty}^{+\infty} x^2 e^{\frac{-x^2}{2}} \cdot \frac{1}{\sqrt{2\pi}} dx$$

$$= 3 \cdot \int_{-\infty}^{+\infty} x^2 e^{\frac{-x^2}{2}} \cdot \frac{1}{\sqrt{2\pi}} dx$$

$$= 3 \cdot \mathbb{E}[X_1^2]$$

$$= 3 \cdot 1 = 3$$

donc: $V\left[\sum_{i=1}^k X_i^2\right] = k [3-1] = 2k$

→ intervalle de confiance à 95% d'une moyenne:

- on calcule la moyenne sur l'échantillon (X_1, \dots, X_n) de la population

$$\bar{x} = \frac{\sum_{i=1}^n X_i}{n}$$

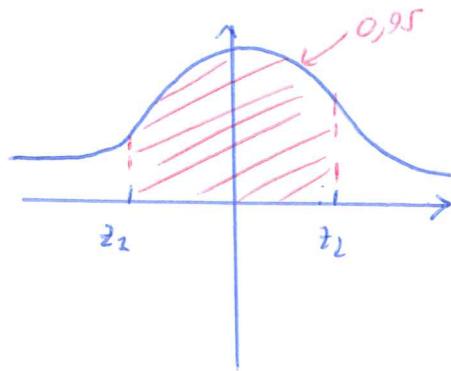
- On suppose que la variable aléatoire suit la loi $N(\mu; \sigma^2)$ [la variance σ^2 est connue]

par conséquent: $\bar{x} \sim N\left(\mu; \frac{\sigma^2}{n}\right)$

donc: $\sqrt{n} \left(\frac{\bar{x} - \mu}{\sigma} \right) \sim N(0; 1)$

(7)

- On cherche z_1 et z_2 tels que: $\mathbb{P}\left(z_1 \leq \sqrt{n} \frac{(\bar{x}-\mu)}{\sigma} \leq z_2\right) = 0,95$



vraisemblance: $z_1 = -1,96$ et $z_2 = 1,96$

$$\text{donc: } -1,96 \leq \sqrt{n} \frac{\bar{x} - \mu}{\sigma} \leq 1,96 \Leftrightarrow \mu \in \left[\bar{x} - 1,96 \cdot \frac{\sigma}{\sqrt{n}} ; \bar{x} + 1,96 \cdot \frac{\sigma}{\sqrt{n}} \right]$$

→ intervalle de confiance à 95% de l'estimation:

- on calcule la variance empirique d'un échantillon (X_1, \dots, X_n) de la population

$$S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{x})^2$$

$$\textcircled{1} \quad \sum_{i=1}^n \frac{(X_i - \bar{x})^2}{\sigma^2} \sim \chi^2(n-1)$$